

# 1. Estimación Bayesiana

La idea fundamental de la estimación bayesiana es que considera que el parámetro desconocido  $\theta$  es una **variable aleatoria**. Como tal,  $\theta$  tiene, antes de observar ningún dato, una función de densidad (o función de probabilidad si es una v.a. discreta) que representa los conocimientos previos o información inicial sobre el parámetro. Esta función de densidad se conoce con el nombre de **distribución a priori**,  $f(\theta)$ .

Esta distribución a priori se modifica basándonos en la información proporcionada por la m.a.s.  $X_1, \dots, X_n$ . Esta información viene representada por la **función de verosimilitud**, que en estimación bayesiana denotaremos por  $f(X_1, \dots, X_n|\theta)$  para expresar el modelo del que provienen los datos condicionado a un valor genérico del parámetro desconocido.

Con estos dos ingredientes y el Teorema de Bayes (versión para v.a., ver glosario) actualizamos la información que tenemos sobre el parámetro  $\theta$ , obteniendo la **distribución a posteriori**  $f(\theta|X_1, \dots, X_n)$ :

$$f(\theta|X_1, \dots, X_n) = \frac{f(X_1, \dots, X_n|\theta)f(\theta)}{\int_{\Theta} f(X_1, \dots, X_n|\theta)f(\theta)d\theta}$$

El denominador no depende de  $\theta$  y actúa como una constante normalizadora para que la integral  $\int f(\theta|X)d\theta$  sea 1. Por lo tanto:

$$A \text{ posteriori} \propto A \text{ priori} \times \text{Verosimilitud}$$

$f(\theta)$  representa la verosimilitud relativa antes de observar la muestra.

$f(\theta|X_1, \dots, X_n)$  representa la verosimilitud relativa después de observar la muestra.

**Definición:** Si las distribuciones a priori y a posteriori pertenecen a la misma familia de distribuciones, esa familia recibe el nombre de **familia conjugada** respecto de la distribución de la muestra de datos (respecto de la función de verosimilitud).

## 1.1. Estimador Bayes

Para formular inferencias con respecto a un parámetro  $\theta$  se usa la distribución a posteriori, que es la a priori modificada una vez observada la muestra. Pero, ¿cómo se usa  $f(\theta|X_1, \dots, X_n)$  para obtener un estimador puntual de  $\theta$ ?

1. Podemos tomar como estimador el máximo, la moda, de la distribución a posteriori, que es el valor más probable, o cualquier otra característica como la mediana o la moda.
2. Podemos definir un criterio de optimalidad y deducir el estimador a partir de él. Definimos una función de pérdida  $g(\hat{\theta}, \theta)$  que evalúe la pérdida que obtenemos usando  $\hat{\theta}$  cuando el verdadero valor es  $\theta$ . Escogeríamos entonces el estimador que minimiza la esperanza a posteriori de esa función de pérdida.

Por ejemplo, si utilizamos la función de pérdida cuadrática o error cuadrático,  $g(\hat{\theta}, \theta) = (\hat{\theta} - \theta)^2$ , el estimador que minimiza esta pérdida con respecto a la distribución a posteriori de  $\theta$  es la media de dicha distribución, si utilizamos la función de pérdida valor absoluto,  $g(\hat{\theta}, \theta) = |\hat{\theta} - \theta|$ , entonces debemos usar como estimador de  $\theta$  la mediana de la distribución a posteriori, si maximizamos la verosimilitud a posteriori, debemos usar la moda, etc.

Los estimadores Bayes son consistentes, se aproximan al verdadero valor del parámetro a medida que aumenta el tamaño muestral. Para  $n$  grande, se aproximan mucho a los EMV (estimadores obtenidos por el método de máxima verosimilitud).

En general, nosotros tomaremos como estimador puntual bayesiano del parámetro  $\theta$ , la media o esperanza de la distribución a posteriori para  $\theta$ , es decir:

$$\hat{\theta} = E[\theta | X_1, \dots, X_n]$$

### CUADRO DE FAMILIAS CONJUGADAS

$\theta \sim$ A PRIORI	$X \theta \sim$ POBLACIÓN	$\theta X_1, \dots, X_n \sim$ A POSTERIORI
$Beta(\alpha, \beta)$	$Ber(\theta)$ $Bin(m, \theta)$	$Beta(\alpha + \sum_{i=1}^n X_i, \beta + n - \sum_{i=1}^n X_i)$ $Beta(\alpha + \sum_{i=1}^n X_i, \beta + mn - \sum_{i=1}^n X_i)$
$Gamma(a, p)$	$\mathcal{P}(\theta)$ $\mathcal{Exp}(\theta)$	$Gamma(a + n, p + \sum_{i=1}^n X_i)$ $Gamma(a + \sum_{i=1}^n X_i, p + n)$
$\mathcal{N}(\mu, \sigma_0)$	$\mathcal{N}(\theta, \sigma)$ con $\sigma$ conocida	$\mathcal{N}\left(\frac{\sigma^2 \mu + n \sigma_0^2 \bar{X}}{\sigma^2 + n \sigma_0^2}, \sqrt{\frac{\sigma^2 \sigma_0^2}{\sigma^2 + n \sigma_0^2}}\right)$

**Ejemplo 1:** Supongamos que la v.a.  $X$  sigue una distribución de Bernoulli,  $X \sim \mathcal{B}er(\theta)$  con el parámetro  $\theta$  desconocido. A su vez, la distribución a priori sobre  $\theta$  es  $f(\theta) \sim$

$Beta(\alpha, \beta)$ . Seleccionando una m.a.s. de  $X, X_1, \dots, X_n$ , calcular la distribución a posteriori  $f(\theta|X_1, \dots, X_n)$ . A partir de esa distribución a posteriori, determinar un estimador Bayes para el parámetro.

$$X \sim \mathcal{Ber}(\theta), \quad P(X = x|\theta) = \theta^x(1 - \theta)^{1-x}, \quad x \in \{0, 1\}$$

La función de verosimilitud será:

$$P(X_1 = x_1, \dots, X_n = x_n|\theta) = \prod_{i=1}^n P(X = x_i|\theta) = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i}$$

La distribución a priori sobre  $\theta$  sabemos que es:

$$\theta \sim Beta(\alpha, \beta), \quad f(\theta) = \frac{1}{\mathcal{B}(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1} \quad \text{para } 0 \leq \theta \leq 1$$

Aplicando el Teorema de Bayes calculamos la distribución a posteriori:

$$\begin{aligned} f(\theta|x_1, \dots, x_n) &= \frac{P(x_1, \dots, x_n|\theta)f(\theta)}{\int_{\theta} P(x_1, \dots, x_n|\theta)f(\theta)d\theta} \\ &= \frac{\theta^{\sum x_i} (1 - \theta)^{n - \sum x_i} \frac{1}{\mathcal{B}(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}}{\int_0^1 \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i} \frac{1}{\mathcal{B}(\alpha, \beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1} d\theta} \\ &= \frac{\theta^{\sum x_i + \alpha - 1} (1 - \theta)^{n - \sum x_i + \beta - 1}}{\int_0^1 \theta^{\sum x_i + \alpha - 1} (1 - \theta)^{n - \sum x_i + \beta - 1} d\theta} \end{aligned}$$

Utilizando la definición de la función  $\mathcal{B}$ eta,

$$\mathcal{B}(\alpha, \beta) = \int_0^1 x^{\alpha-1} (1 - x)^{\beta-1} dx, \quad \text{para } \alpha > 0, \beta > 0$$

Obtenemos la función de densidad de la distribución a posteriori, que es una  $Beta(\sum x_i + \alpha, n - \sum x_i + \beta)$ .

$$f(\theta|x_1, \dots, x_n) = \frac{1}{\mathcal{B}(\sum x_i + \alpha, n - \sum x_i + \beta)} \theta^{\sum x_i + \alpha - 1} (1 - \theta)^{n - \sum x_i + \beta - 1}$$

Podemos utilizar como estimador Bayes, la media de la distribución a posteriori, que en este caso es:

$$\hat{\theta} = \frac{\sum x_i + \alpha}{\alpha + \beta + n}$$

**Ejemplo 2:** Comprobar que la familia gamma es conjugada respecto a la distribución de Poisson para el caso de  $n = 1$ .

Dist. a priori	Verosimilitud	Dist. a posteriori
$\theta \sim \gamma(a, p)$	$X \theta \sim \mathcal{P}(\theta)$	$\theta x \sim ?$

$$f(\theta|x) = \frac{f(x, \theta)}{f_X(x)} = \frac{P(x/\theta)f(\theta)}{\int_{-\infty}^{\infty} P(x/\theta)f(\theta)d\theta} = \frac{e^{-\theta} \frac{\theta^x}{x!} \frac{a^p}{\Gamma(p)} \theta^{p-1} e^{-a\theta}}{\int_0^{\infty} \left( e^{-\theta} \frac{\theta^x}{x!} \frac{a^p}{\Gamma(p)} \theta^{p-1} e^{-a\theta} \right) d\theta}$$

Desarrollamos el denominador:

$$\int_0^{\infty} e^{-\theta} \frac{\theta^x}{x!} \frac{a^p}{\Gamma(p)} \theta^{p-1} e^{-a\theta} d\theta = \frac{a^p}{\Gamma(p)x!} \int_0^{\infty} e^{-(1+a)\theta} \theta^{x+p-1} d\theta = \frac{a^p}{\Gamma(p)x!} \frac{\Gamma(x+p)}{(1+a)^{x+p}}$$

donde hemos utilizado la siguiente propiedad de la función gamma:

$$\int_0^{\infty} x^{p-1} e^{-ax} dx = \frac{\Gamma(p)}{a^p} \text{ siendo } a = b + ic \text{ con } b > 0$$

Así, substituyendo obtenemos la función de densidad a posteriori:

$$f(\theta|x) = \frac{\frac{e^{-(1+a)\theta} \theta^{x+p-1} a^p}{x! \Gamma(p)}}{\frac{a^p}{x! \Gamma(p)} \frac{\Gamma(x+p)}{(1+a)^{x+p}}} = \frac{(1+a)^{x+p}}{\Gamma(x+p)} \theta^{x+p-1} e^{-(1+a)\theta}$$

que es la función de densidad de una Gamma de parámetros  $1+a$  y  $x+p$ , es decir,  $\theta|x \sim \gamma(1+a, x+p)$ .

**Observación 1:** Si operamos algo más en el denominador, obtenemos:

$$f_X(x) = \frac{a^p}{\Gamma(p)x!} \frac{\Gamma(x+p)}{(1+a)^{x+p}} = \dots = \binom{x+p-1}{x} \left( \frac{a}{1+a} \right)^p \left( \frac{1}{1+a} \right)^x \sim BN \left( p, \frac{a}{1+a} \right)$$

Así, la marginal de  $X$  (distribución predictiva de  $X$  a priori) es una distribución binomial negativa con un número fijo de éxitos igual a  $p$  y probabilidad de éxito  $\frac{a}{1+a}$ . Recordemos que en una distribución binomial negativa, la variable aleatoria  $X$  representa el número de fallos antes del  $n$ -ésimo éxito, en este caso, el  $p$ -ésimo ( $n=p$ ).

**Observación 2:** Si consideramos una m.a.s. de tamaño  $n$ , es decir,  $(X_1, \dots, X_n)$ , la función de verosimilitud es:

$$P(\vec{x}|\theta) = P(X_1 = x_1, \dots, X_n = x_n/\theta) = \prod_{i=1}^n e^{-\theta} \frac{\theta^{x_i}}{x_i!} = e^{-n\theta} \frac{\theta^{\sum x_i}}{\prod x_i!}$$

Substituyendo en la expresión

$$f(\theta|\vec{x}) = \frac{P(\vec{x}|\theta)f(\theta)}{\int_{-\infty}^{\infty} P(\vec{x}|\theta)f(\theta)d\theta}$$

y operando igual que antes, obtenemos  $\theta|\vec{x} \sim \gamma(a+n, p + \sum_{i=1}^n x_i)$ .

**Observación 3:** La distribución predictiva de  $X$  a posteriori, es decir, la distribución de probabilidad para una nueva observación de  $X$ ,  $x_n$ , después de haber observado la muestra  $(X_1, \dots, X_n)$ , es:

$$\begin{aligned}
 f(x_n|x_1, \dots, x_n) &= \int_0^\infty f(x_n|\theta, \mathbf{x})f(\theta|\mathbf{x})d\theta \\
 &= \int_0^\infty f(x_n|\theta)f(\theta|\mathbf{x})d\theta \\
 &= \int_0^\infty \left[ \frac{\theta^{x_n} e^{-\theta}}{(x_n)!} \right] \left[ \frac{(a+n)^{p+\sum x_i}}{\Gamma(p+\sum x_i)} \right] e^{-(a+n)\theta} \theta^{p+\sum x_i-1} d\theta \\
 &= \left[ \frac{1}{(x_n)!} \right] \left[ \frac{(a+n)^{p+\sum x_i}}{\Gamma(p+\sum x_i)} \right] \int_0^\infty e^{-(a+n+1)\theta} \theta^{x_n+p+\sum x_i-1} d\theta \\
 &= \left[ \frac{1}{\Gamma(x_n+1)} \right] \left[ \frac{(a+n)^{p+\sum x_i}}{\Gamma(p+\sum x_i)} \right] \left[ \frac{\Gamma(x_n+p+\sum x_i)}{(a+n+1)^{x_n+p+\sum x_i}} \right] \\
 &= \left[ \frac{\Gamma(x_n+p+\sum x_i)}{\Gamma(x_n+1)\Gamma(p+\sum x_i)} \right] \left( \frac{a+n}{a+n+1} \right)^{p+\sum x_i} \left( \frac{1}{a+n+1} \right)^{x_n}
 \end{aligned}$$

Que es una  $BN(p+\sum x_i, \frac{a+n}{a+n+1})$ . La media de esta distribución predictiva a posteriori es la misma que la de la distribución a posteriori, pero su varianza es mayor.